




Fundamentos de Machine Learning

Como computadores aprendem padrões a partir de dados

UC9 — MACHINE LEARNING EM SOLUÇÕES DE IA

CURSO TÉCNICO EM INTELIGÊNCIA ARTIFICIAL

SENAC

O que vamos aprender hoje?

Essa aula é o ponto de partida para entender como máquinas aprendem. Antes de escrever qualquer linha de código, precisamos compreender os conceitos que sustentam todos os modelos que vamos construir nas próximas aulas.



O que é ML?

Diferença entre IA, ML e Deep Learning



Features e Target

O que entra e o que sai de um modelo



Treinamento e Previsão

Da fase de treino à inferência



Como a máquina aprende?

Dados, padrões e ajuste de parâmetros



Tipos de aprendizado

Supervisionado, não supervisionado e por reforço



Regressão, Classificação e Clusterização

Tipos de problemas em ML

Inteligência Artificial é maior que Machine Learning

Esses três termos aparecem com frequência, mas têm significados distintos e uma relação hierárquica clara:

Inteligência Artificial


Campo mais amplo: qualquer técnica que permita a máquinas simular comportamento inteligente — inclui regras, planejamento, agentes e muito mais.


Machine Learning

Subárea da IA: sistemas que aprendem padrões a partir de dados, sem serem explicitamente programados para cada regra.

Deep Learning

Subárea do ML: usa redes neurais profundas com muitas camadas, especialmente eficaz para imagens, texto e voz.





IA × Machine Learning × Deep Learning

Cada camada tem suas próprias técnicas e casos de uso. Veja os exemplos práticos de cada área:

Inteligência Artificial

- Sistemas especialistas com regras
- Agentes autônomos
- Planejamento e busca
- Lógica e raciocínio formal

Machine Learning

- Previsão de preço de imóvel
- Detecção de fraude bancária
- Classificação de clientes
- Sistemas de recomendação

Deep Learning


- Reconhecimento de imagens
- Processamento de linguagem natural
- Reconhecimento de voz
- Modelos generativos (LLMs)

 Atenção: nem toda IA utiliza Machine Learning. Sistemas baseados em regras explícitas também são IA.

Programação Tradicional

Como funciona

Na programação tradicional, o **programador escreve as regras explicitamente**. O computador segue essas regras para produzir um resultado.



Exemplo imobiliário

Imagine um sistema de pré-aprovação de clientes para financiamento:

01

Dados de entrada

Renda mensal, preço do imóvel e percentual máximo de comprometimento

02

Regra programada manualmente

```
if renda > preco * 0.30: return "apto"
```

03


Resultado direto

O sistema retorna "apto" ou "inapto" com base na regra escrita

Funciona bem quando as regras são conhecidas e estáveis. Mas e quando o comportamento real é mais complexo?

Machine Learning Muda a Lógica

No Machine Learning, **não** escrevemos as regras. Fornecemos dados e respostas conhecidas — e o algoritmo descobre os padrões por conta própria.



Programação tradicional


Dados + Regras → Resultado

O programador define cada condição manualmente.

Machine Learning

Dados + Respostas → Modelo → Previsões

O algoritmo encontra os padrões nos dados.



O que Significa uma Máquina "Aprender"?

Apesar do termo, a máquina não aprende como um ser humano. O aprendizado de máquina é um processo matemático de **ajuste de parâmetros** para minimizar erros.

1

Observa exemplos

Recebe pares de entrada e saída esperada

2

Identifica relações

Detecta padrões entre as variáveis

3

Ajusta parâmetros

Modifica valores internos para reduzir o erro

4

Generaliza

Aplica o aprendizado a dados que nunca viu



A máquina não "entende" o problema como nós. Ela ajusta parâmetros matemáticos até que as previsões sejam suficientemente precisas.

Um Exemplo Simples com Imóveis

Imagine que temos um pequeno histórico de imóveis vendidos. Com base nesses dados, queremos **estimar o preço de um imóvel novo de 70 m²**.

Área	Quartos	Vagas	Preço
45 m ²	1	1	R\$ 280 mil
60 m ²	2	1	R\$ 390 mil
75 m ²	3	2	R\$ 520 mil
90 m ²	3	2	R\$ 610 mil
70 m ²	?	?	???

O que o ML faz?

O algoritmo analisa os exemplos anteriores, identifica a relação entre área, quartos, vagas e preço, e **tenta prever o preço do imóvel desconhecido**.

Não escrevemos nenhuma fórmula. Mostramos os dados — e o modelo aprende a relação.

O que são Features?

Features (ou variáveis de entrada) são as características que o modelo usa para tomar uma decisão ou fazer uma previsão.

Quanto mais informativas forem as features, melhor o modelo consegue aprender.

 Área (m²)

 Quartos

 Vagas

 Bairro

 Andar

 Idade

Fluxo de decisão

Imóvel

Features

Modelo de ML

As features são a "visão" do modelo sobre o mundo. Ele só sabe o que você mostrar a ele.

O que é Target?

O **target** (ou variável de saída) é aquilo que queremos prever. É a resposta que o modelo deve aprender a produzir a partir das features.



Imóvel

Features: área, quartos, vagas

Target: preço do imóvel



Cliente

Features: renda, idade, histórico

Target: vai comprar ou não?



E-mail

Features: palavras, remetente, frequência

Target: spam ou não spam?

X e y — A Notação do Scikit-learn

Nos notebooks de Machine Learning, você verá constantemente essa notação. É a forma padrão de separar features e target em código Python.

X — Features (entradas)

Matriz com todas as variáveis de entrada. Cada linha é um exemplo, cada coluna é uma feature.

y — Target (saída)

Vetor com os valores que queremos prever. Um valor por exemplo.

Exemplo em Python

```
import pandas as pd

# Carregar dados
df = pd.read_csv("imoveis.csv")



# Separar features e target
X = df[["area", "quartos", "vagas"]]
y = df["preco"]

# X tem 3 colunas (features)
# y tem 1 coluna (target)
print(X.shape) # (100, 3)
print(y.shape) # (100,)
```

Essa convenção é usada em toda a biblioteca **Scikit-learn** e é fundamental para criar e treinar modelos.

Treinamento — Como o Modelo Aprende

Treinar um modelo significa expô-lo a exemplos conhecidos e **ajustar seus parâmetros internos** até que ele consiga fazer previsões cada vez mais precisas.



- ❏ Nesta aula não vamos aprofundar gradiente descendente ou derivadas. Esses conceitos serão apresentados em aulas futuras.

Inferência — Usando o Modelo Treinado

Treinamento

Ocorre **uma vez** (ou periodicamente), usando dados históricos com respostas conhecidas.

- Algoritmo aprende padrões
- Parâmetros são ajustados
- Modelo é salvo para uso posterior

Exemplo: 10.000 imóveis com preços já conhecidos.

Inferência (Previsão)

Ocorre **sempre que necessário**, usando o modelo já treinado para analisar dados novos.

- Dados novos entram no modelo
- Modelo aplica o que aprendeu
- Gera uma previsão instantânea

Exemplo: novo imóvel sem preço, aguardando estimativa.

 Treinamento e inferência são fases separadas. Em produção, o modelo já está treinado — e apenas faz previsões em tempo real.

Os Três Grandes Tipos de Aprendizado

A forma como um modelo aprende depende fundamentalmente do tipo de dado disponível e do objetivo do problema. Existem três paradigmas principais:



Supervisionado

Temos exemplos **com respostas conhecidas**. O modelo aprende a relação entre entrada e saída.

Ex: preço de imóvel, spam ou não spam.



Não Supervisionado

Temos dados, mas **sem respostas prontas**. O modelo descobre estruturas e padrões ocultos.

Ex: agrupamento de perfis de clientes.



Por Reforço

Um agente aprende através de **ações e recompensas**, interagindo com o ambiente.

Ex: robô aprendendo a caminhar, jogo de xadrez.

Aprendizado Supervisionado

No aprendizado supervisionado, cada exemplo de treinamento possui uma entrada (X) e uma resposta correta (y). O algoritmo aprende a mapear $X \rightarrow y$.

É o tipo mais comum de ML e a base dos modelos que usaremos nos projetos imobiliários.

Exemplos práticos

- Prever preço de imóvel (regressão)
- Prever inadimplência de cliente
- Detectar fraude em transação
- Classificar leads por probabilidade de compra

Fluxo do aprendizado supervisionado



Regressão — Prevendo um Valor Numérico

Regressão é um problema de aprendizado supervisionado onde o **target** é um **valor numérico contínuo**. A pergunta central é: *"Qual número devemos prever?"*

Preço de imóvel

R\$ 487.350

Estimado com base em área, quartos e localização

Temperatura

28,5 °C

Prevista com base em dados climáticos históricos

Faturamento

R\$ 1,2M

Projetado com base em histórico de vendas

Demanda

340 unidades

Estimada para o próximo mês

 Em regressão, o modelo não escolhe entre categorias — ele produz um número. Quanto maior ou menor esse número for, mais próximo ou distante da realidade estará a previsão.

Classificação — Prevendo uma Categoria

Classificação é um problema de aprendizado supervisionado onde o **target é uma categoria ou classe**. A pergunta central é: *"A qual grupo este exemplo pertence?"*

Exemplos imobiliários

- Fraude / Não fraude em transação
- Cliente compra / não compra o imóvel
- Documento válido / inválido
- Lead quente / morno / frio

Classificação binária vs. multiclasse

Binária

Apenas **duas** classes possíveis.
Spam ou não spam. Fraude ou legítimo.

Multiclasse

Três ou mais classes possíveis.
Lead quente / morno / frio / inativo.



Aprendizado Não Supervisionado

Como funciona?


No aprendizado não supervisionado, **não existe um target previamente definido**. O algoritmo recebe apenas os dados de entrada e tenta encontrar estruturas, padrões ou agrupamentos por conta própria.

- Encontrar grupos similares
- Detectar anomalias e comportamentos incomuns
- Reduzir dimensionalidade dos dados
- Descobrir padrões ocultos

Exemplo imobiliário

Uma imobiliária possui **milhares de clientes cadastrados**, mas nunca os categorizou em perfis.

Com aprendizado não supervisionado, é possível identificar automaticamente grupos de clientes com comportamentos semelhantes — sem que ninguém precise definir os grupos antecipadamente.



Clusterização — Agrupando o que é Parecido

Clusterização é a principal técnica de aprendizado não supervisionado. O algoritmo agrupa as observações com base em **similaridade entre as features**, sem receber nenhuma instrução sobre quais grupos existem.

Cluster 1 — Jovens compradores

- Primeiro imóvel
- Orçamento menor
- Priorizam localização e transporte

Cluster 2 — Famílias

- Buscam 3+ quartos
- Priorizam área e infraestrutura
- Valorizam espaço externo


Cluster 3 — Investidores

- Foco em rentabilidade
- Múltiplos imóveis
- Priorizam retorno financeiro

 Os grupos não são fornecidos ao algoritmo. Ele os descobre sozinho com base nos padrões dos dados.

Aprendizado por Reforço

No aprendizado por reforço, um agente aprende interagindo com um ambiente. A cada ação, recebe uma recompensa (positiva ou negativa) e, ao longo do tempo, aprende a tomar as melhores decisões.



Conceitos principais



Agente

Quem toma as decisões



Ambiente

O mundo com que o agente interage



Ação

O que o agente faz a cada passo




Recompensa

Sinal que indica se a ação foi boa ou ruim

Como Identificar o Tipo de Problema?


Antes de escolher um algoritmo, é fundamental entender o tipo de problema que você está resolvendo. Faça estas perguntas em sequência:



Essa sequência de perguntas ajuda a definir o caminho antes de escolher qualquer algoritmo ou biblioteca.

Etapas de um Projeto de Machine Learning

Treinar o modelo é apenas **uma das etapas** de um projeto completo. Na prática, a maior parte do esforço está na preparação dos dados e na avaliação dos resultados.




☐ Em projetos reais, as etapas de coleta, limpeza e preparação de dados costumam ocupar mais de 70% do tempo total do projeto.

Machine Learning no Projeto Imobiliário

Você já estudou Agentes de IA na UC9. Agora, os modelos de Machine Learning entram como **ferramentas especializadas dentro do agente**.

Arquitetura integrada



Ferramentas do agente



Consulta ao banco de imóveis

Recupera imóveis disponíveis por filtros



Modelo de Regressão

Estima o preço de um imóvel com base nas features



Modelo de Classificação

Qualifica o lead: quente, morno ou frio



Modelo de Clusterização

Identifica o perfil do cliente automaticamente

Revisão — O que Aprendemos Hoje



IA > ML > Deep Learning

Relação hierárquica entre os campos



Features e Target (X e y)

Entrada e saída de um modelo



Treinamento e Inferência

Aprender vs. prever com dados novos



Tipos de aprendizado

Supervisionado, não supervisionado, reforço



Regressão e Classificação

Prever valores numéricos ou categorias



Clusterização

Agrupar dados sem respostas pré-definidas

Próxima aula: Do dado ao primeiro modelo de Machine Learning

Como podemos pegar uma base de imóveis e fazer o computador aprender a relação entre suas características e seus preços? A próxima aula será predominantemente prática em notebook.



Orientações para a Próxima Aula

Na próxima aula, saímos da teoria e vamos **construir nosso primeiro modelo de Machine Learning em Python**. Aqui está o que você precisa saber para chegar preparado:

1 Tenha o Python e o Jupyter funcionando

Certifique-se de que seu ambiente está configurado com `pandas`, `scikit-learn` e `matplotlib` instalados.

2 Revise a notação X e y

Você usará `X = df[["feature1", "feature2"]]` e `y = df["target"]` constantemente durante a aula prática.

3 Pense nos conceitos de hoje

Features, target, treinamento e inferência são os pilares que usaremos para escrever cada linha de código da próxima aula.



Bons Estudos!

Dúvidas, reflexões ou exemplos que você quer trazer para a aula?
Compartilhe com a turma!

 UC9

Machine Learning em
Soluções de IA

 SENAC

Curso Técnico em Inteligência
Artificial

 Próxima aula

Do dado ao primeiro modelo — prática em notebook